

FlagOS赛道三技术报告

基于"史书论"的自适应ICL长上下文数据标注方案

团队名称: 21064

成员: 甘孙逸

2026年5月20日

摘要

长上下文场景下的上下文学习（In-Context Learning, ICL）面临严重的注意力稀释问题——大量低质量示例会分散模型注意力，反而降低标注准确性。受"史书只记录高光时刻"的启发，本方案提出"史书论"示例筛选方法：通过分析模型错误模式，从海量训练数据中筛选最具教学价值的"高光示例"作为上下文，使模型在有限的上下文窗口内聚焦关键信息。

在实验推进过程中，本方案围绕四项核心思想——史书论、海马体检索构想、重试机制、高光示例——进行了三轮递进式实验。结果显示，不同任务类型对推理策略存在显著的差异化需求。据此，本方案逐步进化出一套"任务自适应调度"策略：对确定性数学任务采用工具函数直接计算，准确率达100%；对知识密集型任务引入海马体检索机制，准确率从27.6%提升至78.8%；对主观分类任务采用极简提示词配合递进式重试，准确率达81%；对代码生成任务采用检索增强配合代码提取策略。最终，本方案在全部8个数据集上取得了68.93分的总成绩。

通过三轮递进式实验，本方案系统性地验证了示例质量对ICL性能的决定性影响，量化了Qwen3-4B模型在多个任务上的能力边界，并完整记录了四项核心思想从提出、并行验证、到最终汇聚成"任务自适应调度"系统方法论的进化过程。

1. 研究背景与动机

1.1 长上下文ICL的核心困境与理论依据

近年来，大语言模型的上下文窗口持续扩展，但上下文学习性能并不总是随之提升。Yuan等人（2024）在EMNLP上发表的研究指出，在多样本设置中，过多示例会分散模型对查询的注意力，阻碍其对关键内容的理解。他们提出的FocusICL方法通过过滤无关内容和层级化注意力机制，取得了平均5.2%的性能提升。

在比赛初期，我在数据集3（Collatz猜想）上的基线实验也印证了这一发现：采用标准ICL策略（随机抽取20条示例），测试集准确率仅为32.0%。通过对全部错误样本的逐一分析，我发现了高度集中的错误模式：全奇数列表的错误率高达96.15%，长序列（长度 ≥ 7 ）的错误率普遍超过79%。这些数据表明，随机示例中缺乏模型真正需要的"教学信号"。

1.2 "史书论"思想的诞生

中华五千年历史，为什么一本《资治通鉴》就能写完大半？因为司马光只记录那些影响历史走向的关键事件——赤壁之战、安史之乱、王安石变法——而不会浪费笔墨去记录某个皇帝中午吃了什么。随机给模型塞进几十条训练样本，就像给历史学家一本没有剪裁的流水账日记，他根本无法从中提炼规律。真正有效的做法，应当像司马光那样，只把最具教学价值的"高光示例"放进上下文中。

基于上述错误模式分析，我从训练集中有针对性地筛选出覆盖全奇数、长序列、含大数等高错误率情况的20条"高光示例"。实验结果显示，数据集3的准确率从32%飙升至63.6%，绝对提升31.6个百分点。

2. 方案设计

2.1 第一阶段：基于错误模式驱动的"高光示例"筛选

在比赛的第一阶段，我首先在数据集3上进行了基线测试。通过对340条错误样本的深入分析，我按照列表奇偶类型和列表长度两个维度进行了错误分类：

全是奇数的列表错误率：0.9615384615384616

按长度分组错误率：

长度 2：错误率 47.06% (24/51)

长度 3：错误率 52.11% (37/71)

长度 4：错误率 53.03% (35/66)

长度 5：错误率 72.73% (48/66)

长度 6：错误率 72.73% (48/66)

长度 7：错误率 79.10% (53/67)

长度 8：错误率 78.95% (45/57)

长度 9：错误率 89.29% (50/56)

无大数的列表错误率：0.68

===== 按奇偶类型统计 =====

all_odd：错误率 96.15% (25/26)

all_even：错误率 0.00% (0/28)

mixed：错误率 70.63% (315/446)

图1：数据集3基线错误模式统计（按列表长度与奇偶类型）

列表类型	错误率	解读
全奇数	96.15%	模型几乎完全无法处理全奇数列表
全偶数	0.00%	偶数处理毫无问题
混合	70.63%	超过三分之二的混合样本出错

列表长度	错误率
2	47.06%
3	52.11%
4	53.03%
5	72.73%
6	72.73%
7	79.10%
8	78.95%

列表长度	错误率
9	89.29%

Top 1 (严重度: 6.84)

输入: [101, 116, 22, 20, 122, 53, 138, 150]

真实: [304, 58, 11, 10, 61, 160, 69, 75]

预测: [506, 579, 111, 100, 610, 160, 690, 750]

原始输出片段: [506, 579, 111, 100, 610, 160, 690, 750]

图2: 模型杀手样本示例 (Top 1)

Top 2 (严重度: 4.75)

输入: [185, 168, 110, 2, 138, 94, 183, 23]

真实: [556, 84, 55, 1, 69, 47, 550, 70]

预测: [925, 840, 550, 1, 690, 470, 915, 115]

原始输出片段: [925, 840, 550, 1, 690, 470, 915, 115]

图3: 模型杀手样本示例 (Top 2)

基于这些发现, 我设计了针对性的筛选规则。实验结果显示: 基线准确率32.0%, 史书论准确率63.6%, 绝对提升31.6个百分点。

2.2 第二阶段: 四项核心思想的并行验证

在方案初期, 我已同时构想了四项核心思想——史书论(固定筛选)、海马体检索构想、重试机制、高光示例(分层组织)。第一阶段仅验证了史书论在数据集3上的有效性, 其余三项思想尚未经过实验检验。第二阶段的核心任务, 是将这四项思想分别在不同数据集上进行独立验证, 观察其实际表现, 并根据实验结果决定各自的进化方向。

以下为三轮实验的阶段概览:

实验阶段	时间	核心目的	涉及数据集
Exp-A: 思想验证	2月中旬	验证史书论与高光示例的有效性	1, 3, 4
Exp-B: 策略推广	2月下旬-3月	并行检验海马体检索、重试机制、分块批量推理, 推广至全部任务	2, 5, 6, 7
Exp-C: 系统整合	4月-5月	将各项策略整合为任务自适应调度框架	全部 (除数据集8)

2.2.1 海马体检索构想：数据集7的独立验证

海马体检索构想的核心是"动态记忆"——在推理时为每个测试样本从训练集中实时检索最相关的示例，而非使用固定的示例集。这一构想最初并非从史书论"进化"而来，而是独立提出的另一种示例选择策略。

我在数据集7（Jeopardy问答）上对海马体检索进行了独立验证。该任务基线准确率仅为27.6%，固定示例策略效果十分有限。我使用SequenceMatcher作为相似度匹配算法，在推理时动态检索与当前测试样本最相似的3条训练样本作为上下文。此外，针对数据集7的输出特点，我进行了三项针对性修复：锁死温度为0.0以消除输出随机性、放宽单字符答案的过滤以避免漏掉简短正确答案、保留原始大小写不再强制转为小写。




图4：海马体检索机制流程图

实验结果显示，数据集7的验证集准确率从27.6%飙升至78.8%，提升51.2个百分点。海马体检索构想的有效性得到充分验证，正式确立为本方案的核心机制之一。

2.2.2 重试机制的独立验证与进化

重试机制的原始构想十分朴素：当模型输出格式错误时，自动重新调用API。这一思想最先在数据集7的实验中得到应用——由于数据集7的输出格式要求较为灵活，模型偶尔会输出不符合预期的内容，简单的重试即可有效解决。

然而，在将重试机制推广至数据集5/6时，我发现单纯的"重新调用"并不总能解决问题。模型有时会连续多次输出相同格式的错误答案。为此，我将重试机制升级为递进式重试：每轮重试不仅重新调用API，还同步降低温度并升级提示词约束——从"只输出答案"逐步收紧为"直接输出标签"——从而在不引入额外随机性的前提下提升输出稳定性。

实验证明，递进式重试能够有效挽救格式错误的输出，且不会对正确输出的样本产生负面影响。这一机制因此被确立为本方案的通用增强策略，应用于数据集5/6/7的最终方案中。

2.2.3 高光示例的推广与废弃

高光示例（按标签分组的"分层示例"策略）在数据集3上取得了显著成效——通过按标签将示例分组并在组间插入过渡标记，准确率从32%提升至63.6%。这一成功促使我将其推广至数据集5/6。

然而，推广实验结果令人失望。在数据集6上，分层示例策略的准确率仅为64.2%，相比基线73.4%骤降9.2个百分点。事后分析，失败原因在于分层组织引入了"标签块化偏差"：当模型在上下文中连续看到多条相同标签的示例后，会过度依赖这一局部模式，从而忽视当前测试样本的具体特征，导致误判。




图5：分层示例策略对数据集6准确率的影响

基于这一清晰的实验结果，我果断废除了分层示例策略。数据集5/6转而采用极简提示词方案——不给模型任何分组暗示，仅通过简洁的指令和递进式重试来保障输出质量。这一废弃经历也带来了重要的认知收获：对于4B量级的小模型而言，减轻认知负担远比增加结构化信息更有效。

2.2.4 长文本计数：分块批量推理的尝试与回归

数据集2（词性统计）的任务是统计英文句子中名词或动词的数量。在Exp-B阶段，我为该任务设计了两种不同的实验方案进行对比。

方案一：单样本推理。沿用与其他分类任务相同的模式，为每个测试样本独立构建提示词并调用API。这种方法稳定性较高，但每次调用只能处理一条样本，对长上下文窗口的利用率较低。

方案二：分块批量推理。将所有500条测试样本按每批50条进行切分，每批使用同一套固定示例（20条全特征覆盖示例），要求模型按“任务编号：数字”的格式一次性输出该批所有样本的答案。这种方法核心理念是充分利用长上下文窗口的容量，减少API调用次数的同时，让模型在同一批次的上下文中看到更多同类样本，从而提高统计的稳定性。

实验结果：分块批量推理在验证集上取得了77.4%的最优准确率，优于单样本推理的表现。这一结果验证了“长上下文批量处理对计数类任务有效”的假设——计数任务本质上是模式匹配，批量处理能够让模型在同一上下文中反复强化“识别名词/动词→数数→输出数字”的映射关系。

然而，在后续的Exp-C阶段，受限于FlagScale服务的max_model_len配置（8192 tokens），每批处理50条样本时提示词总长度经常触及上下文窗口上限，导致部分批次的输出被截断。考虑到提交的稳定性，最终方案中数据集2回归了单样本推理模式，保留了全特征覆盖示例集和重试机制，但不再使用分块批量处理。验证集77.4%的成绩作为方案有效性的证明被记录，但最终提交的实际得分因上述环境限制而无法确定。

2.2.5 工具函数的独立发现

在数据集1（最小绝对差）和数据集4（字符串拼接）上，模型即使使用高光示例仍会在数值推理上出错。这一现象并非来自某条思想的"进化"，而是一个独立发现：对于确定性任务，大模型的可靠性天然不如传统算法。我直接编写Python工具函数绕过模型，三个数学任务的准确率全部达到100%。这一发现后来成为"任务自适应调度"中最重要的分支之一。

2.3 第三阶段：最终方案体系

经过两个月的迭代，四项核心思想经过独立验证和各自进化，最终汇聚为一套"任务自适应调度"策略。以下是各数据集的最终方案及其实验准确率：




图6：任务自适应调度策略概览

任务类型	数据集	核心策略	验证集准确率
确定性计算	1, 3, 4	工具函数直接计算	100%

任务类型	数据集	核心策略	验证集准确率
知识检索	7	海马体检索 + 三项修复	78.8%
主观分类	5	极简提示词 + 递进式重试	81%
主观分类	6	极简提示词 + 递进式重试	73.4%
长文本计数	2	极简提示词 + 随机采样	77.4%
代码生成	8	检索增强 + 代码提取	—（无法得知）

注：验证集是在训练集当中随机抽取相应的数据进行实验。

最终提交总分：68.93分。其中数据集1/3/4均获满分，数据集7的提升幅度最大（+51.2个百分点），数据集5/6/2维持在模型能力上限附近，数据集8受限于Qwen3-4B的代码生成硬天花板，仅通过检索增强策略保底得分。

3. 实验设计与思想进化

本章完整记录本方案从最初构想逐步进化为系统方法论的实验过程。数据集8（Triton代码生成）因官方评测采用代码编译与执行正确性标准，本地无法自行测量准确率，故不参与本章的实验验证。代码生成任务的模型上限已由KernelBenchX等基准实验所证实：当前最先进的代码LLM在生成高效Triton算子方面仍面临重大困难。该任务在方案早期即已确定采用检索增强配合代码提取的逻辑。

3.1 核心思想与实验路线总览

在方案启动之初，我已明确提出了四项核心思想——史书论、海马体检索构想、重试机制、高光示例筛选。在后续两个月里，我围绕这四项思想进行了三轮递进式实验，逐步验证其有效性，并根据实验结果不断修正和深化。

实验阶段	时间	核心目的	关键变量	涉及数据集	主要发现
Exp-A：思想验证	2月中旬	验证史书论与高光示例的有效性	示例选择方式（随机vs筛选）、示例数量（20条）	1, 3, 4	史书论显著有效（32%→63.6%）；高光示例在数据集3初步验证；工具调用雏形出现

实验阶段	时间	核心目的	关键变量	涉及数据集	主要发现
Exp-B: 策略推广	2月下旬-3月	并行检验海马体检索、重试机制、分块批量推理，推广至全部任务	检索方式（随机vs动态）、推理模式（单样本vs分块批量）、温度（0.0vs0.7）、重试次数（1-5）	2, 5, 6, 7	海马体检索有效（27.6%→78.8%）；分块批量推理在数据集2验证集达到77.4%；高光示例在5/6失效并废除；重试机制进化为递进式；发现"不同任务需要不同策略"
Exp-C: 系统整合	4月-5月	将各项策略整合为任务自适应调度框架	温度配置（按任务分配）、输出格式（标签vs纯文本）、后处理逻辑	全部（除数据集8）	数据集2因上下文限制回归单样本推理；确定各任务最优参数；四项思想最终汇合为"自适应调度"框架；最终得分68.93




图7：各数据集验证准确率对比（最终策略）

3.2 实验变量的演变与挑战

挑战一：实验变量的不一致。在早期基线测试中，所有任务均使用TEMPERATURE=0.0和开启思考模式。然而，随着实验深入，我逐渐发现不同任务对温度和思考模式的需求截然不同：数据集5/6在温度0.7配合关闭思考模式时表现更稳定；数据集7则需要锁死温度0.0来避免模型"胡编"。因此，我在后续实验中主动打破了参数的一致性。这并非实验设计缺陷，而是在实验过程中发现了"任务类型与最优参数之间存在强关联"这一规律后，做出的科学决策。

挑战二：四项思想的并行进化。在方案启动时，我所构想的四层思想并非线性进化关系，而是四条并行线路，各自经历独立的验证和发展，最终汇合为"任务自适应调度"框架。

3.3 思想进化路径图

原始思想	Exp-A结果	Exp-B结果	最终形态
史书论（固定筛选高光示例）	数据集3成功（+31.6%）	推广至数据集7时发现固定规则无法满足动态需求	→ 进化为任务自适应调度（动态检索+工具调用）
海马体检索构想（动态记忆）	未测试	数据集7验证有效（+51.2%）	→ 正式确立为海马体检索机制
重试机制（简单重试）	未测试	数据集7/5/6验证有效	→ 进化为递进式重试策略
高光示例（分层组织）	数据集3初步验证	数据集5/6失败（-9.2%），被废除	→ 废弃，转为极简提示词（减负比复杂更有效）

3.4 实验结论

通过三轮递进式实验，我得出以下核心结论：

1. 示例质量比数量更重要：史书论在数据集3上的31.6个百分点提升，直接证明了这一结论。
2. 不同任务需要不同策略：确定性计算适合工具函数，知识检索适合动态示例匹配，主观分类适合极简提示词。
3. 模型存在天然的能力上限：数据集5的131轮穷举搜索表明，81.2%是Qwen3-4B在该任务上的硬上限。
4. 参数调整应有任务针对性：温度、思考模式等参数需要根据任务类型灵活配置，而非一刀切。

这些结论共同构成了"任务自适应调度"方法论的理论基础，也是本方案最核心的技术贡献。

4. 深度分析与反思

4.1 探索过程的完整记录

回顾整个参赛历程，我的技术路线经历了三次重要转折。

第一次转折（2月）：从随机示例到史书论筛选。在数据集3上，我发现了错误模式分析的强大威力，验证了"高光示例"思想的有效性，准确率从32%飙升至63.6%。

第二次转折（3-4月）：从单一规则到四项思想的并行验证。史书论在数据集7的推广需求催生了海马体检索；重试机制逐步进化为递进式；高光示例在数据集5/6的失败促使我转向极简提示词；工具函数让三个数学任务满分。四项思想分别在不同的任务上得到了验证，同时也暴露了各自的局限性。

第三次转折（4-5月）：从并行探索到系统整合。我将四项思想的所有经验汇聚为"任务自适应调度"框架——不是某一条思想的单独进化，而是四条并行线路的交汇。最终在全部8个数据集上取得68.93分。

4.2 任务自适应调度策略的形成

经过充分的实验验证，我得出结论：任务类型是决定最优策略的第一要素。确定性任务中，大模型不如传统算法可靠，应完全外包给工具函数；知识检索任务中，动态示例检索能大幅提升性能；主观分类任务中，提示词设计和输出格式约束是关键；复杂生成任务在4B量级模型上，保底策略比冒险生成更可靠。

4.3 模型能力边界的量化认知

通过大量实验，我系统地量化了Qwen3-4B在多个任务上的能力上限：情感分类约81%、体裁分类约73.4%、知识问答约78.8%、代码生成无法自主完成（这一发现与KernelBenchX基准测试中"72%的Fusion任务在所有五种方法中均失败"的结论高度一致）。这些数据有力地证明：优化只能逼近上限，无法突破模型自身的天然边界。

4.4 对FlagScale框架的未来建言

基于本次比赛长达两个月的实战体验，我想对FlagScale框架官方提出以下三条建议：

第一，增强跨芯片的通用适配能力。在比赛过程中，我使用的是华为910 B NPU环境，仍遇到了显存管理、KV缓存配置等与芯片特性相关的适配问题。如果未来FlagScale能够进一步屏蔽底层硬件差异，提供统一的接口，让开发者只需关心业务逻辑，将极大降低AI应用的门槛。

第二，建立动态Token管理与自动参数推荐机制。在推理过程中，我多次遭遇因max_tokens设置不当导致的输出截断或空值问题。如果框架能够自动监测输入Token使用量，动态调整输出空间，并根据任务类型自动推荐最优推理参数，将能大幅减少开发者的试错成本。

第三，持续深化"无感"生态兼容。FlagScale目前已经支持超过20种AI芯片，但不同芯片的"语言"和生态仍有差异，开发者往往需要额外学习特定芯片厂商的工具链。希望框架能进一步统一开发体验，让开发者单靠学习FlagScale一套框架，就能平滑完成在不同芯片上的部署和运行。

5. 总结与展望

5.1 核心贡献

第一，提出了"史书论"ICL示例筛选思想，并在数据集3上验证了其有效性：准确率从32%提升至63.6%，绝对提升31.6个百分点。第二，设计并验证了一套完整的任务自适应调度策略，成功覆盖全部8个数据集的多样化需求，在数学任务上达到100%准确率，在知识问答任务上将准确率从27.6%提升至78.8%。第三，通过三轮递进式实验，系统性地记录了四项核心思想从提出、并行验证、各自进化、到最终汇聚为系统方法论的完整过程。

5.2 未来方向

未来，我计划参加全国青少年人工智能创新大赛，继续沿袭"任务自适应调度"策略，并尝试引入Qwen3-Coder-Next等专业代码模型。同时，我计划将通过FlagOS比赛积累的工程实践经验，应用于后续的AI科创项目中。

附录A：个人介绍与参赛经历

我叫甘孙逸，今年14岁，是一名初二学生。参加这次FlagOS全球挑战赛，是我第一次真正动手实践AI，也是第一次独立完成一个完整的技术项目。

2025年11月-2026年1月：自学吴恩达《Generative AI for Everyone》课程，掌握了大模型的基础原理。学完课程后，我意识到自己只停留在概念层面，缺乏真正的动手实践。于是我报名了FlagOS比赛——不是为了拿奖，而是为了把课程里学到的ICL、few-shot prompting等概念在真实场景中跑一遍。

2026年2月：独立完成了Qwen2.5-0.5B模型的DSW微调实验，熟悉了模型训练的基本流程。同月，报名FlagOS开放计算全球挑战赛赛道三，独立完成了基线实验和数据分析，发现了长上下文场景下的注意力稀释问题，并据

此提出了"史书论"思想。

附录B：AI辅助声明

本方案的所有原创算法思想（史书论、海马体检索、工具调用、任务自适应调度等）、核心实验设计与数据分析均由我独立完成。Python代码实现过程中使用了DeepSeek和Kimi进行辅助编写和调试；技术方案文档使用了GLM和DeepSeek进行语言润色和格式优化。所有实验数据均为真实运行结果，未使用AI生成或篡改，保证了技术的真实性。

附录C：代码与可复现性

完整方案代码（包括method.py、模型部署脚本、环境依赖文件）已随本报告一并提交至FlagOS竞赛平台。此外，68.93分时的稳定方案代码将于比赛结束后开源至GitHub仓库，以供评委复现和社区参考。