

超长长上下文 LLM 自动数据标注：技术报告

项目：FlagOS OpenSeek 八任务 (Task 1–8)
评测集：官方 `examples` （带金标，用于离线调参与对比）
指标：`is_match` (`model_output` 与 `expected_output` 一致)；Task 8 另报执行器判据 `exec_dual_pass`
数据依据：`examples/` 下 `openseek-*-examples-compare*.jsonl` 及同目录 `summary*.json` （辅以 `examples_main1*`、`examples_task7`、`examples_thinking` 等对照实验）

摘要

本报告总结在 OpenSeek 八任务上，通过 **错例驱动 (badcase) 工程**、**分层后处理** 与 **Autoresearch 自主 prompt 优化** 提升标注准确率的方法与实验结果。核心结论如下：

Task	基线 (examples)	最佳 (examples 实测)	提升幅度	主路径
1	97.93%	≈99.95% (后处理理论)	+2pp	L0 标签清洗
2	70.42%	89.17%	+18.8pp	L1 spaCy 零样本 prompt
3	98.92%	≈100% (后处理)	+1.1pp	L0 列表抽取
4	—	100%	—	L0 拼接规则
5	74.09%	81.09% (+后处理 eval)	+7.0pp	L1 badcase + L0 校准
6	68.99%	83.11%	+14.1pp	L1 句级 + 后处理 v2/v3
7	28.81%	37.81% (stept, 见 examples_task7)	+9.0pp	L1 prompt + L2 autoresearch
8	0% (字符串)	74.46% (执行器, thinking)	—	L1 契约 + ReAct + 执行评测

1. 问题与设定

1.1 任务概览

Task ID	名称	examples 规模 (本仓库实测)	难点
1	closest_integers	5500 (ranktest)	长列表推理、输出格式
2	count_nouns_verbs	5440 (main1)	词性统计、ICL 干扰
3	collatz_conjecture	3997	列表复述、标签包裹
4	conala_concat_strings	2815 (task24)	模型加空格/偏离拼接
5	tweet_sadness	1899	emoji/hashtag、FP/FN 边界
6	mnli_same_genre	5500	体裁判断、句对组合
7	jeopardy_answer	5499	开放短答案、归一化
8	kernel_generation	184	可执行代码、非字符串匹配

1.2 实验协议

- 在 **examples** 上运行 `src/infer_examples*.py`，产出 `examples/openseek-{task}-examples-compare*.jsonl`。
- 每条记录含 `input`、`expected_output`、`model_output`、`is_match`。
- 汇总文件：`examples/summary*.json` 或由脚本内 `_compute_metrics_from_jsonl` 生成。

4. 禁止在 test_samples（无金标）上调参；test 仅用于最终提交。


2. 方法论

2.1 三层优化架构

- L0 确定性层 → postprocess_task*（解析、规则、真值覆盖）
- L1 工程层 → 专用 prompt、badcase few-shot、管线拆解、投票融合
- L2 Autoresearch → failure_analysis + meta-LLM 改 prompt + 子集闭环评估

- L0 优先：消除「答案对、格式错」的假阴性（Task 1/3/4 收益最大）。
- L1 主路径：针对语义与结构错误，结合 badcase 统计改 prompt 或拆分子任务（Task 2/5/6/8）。
- L2 加速：Task 7 等开放生成任务，用 autoresearch_prompt.py 自动迭代 system/user 模板（见 §2.3）。

2.2 错例驱动（Badcase）流程



Task 5 典型 badcase 模式（驱动 FIXED_TASK5_FS_SHOTS 8 条）：

类型	表现	金标倾向	对策
假阳性 FP	感激+😭、歌词、推广噪声	Not sad	固定 few-shot + fp_suppress 正则
假阴性 FN	丢钥匙、被吵醒、口语 so bad	Sad	固定 few-shot + text_calib
emoji 误导	单 emoji 判 Sad	依语境	examples 共现比例 + 感激语境压 FP

2.3 Autoresearch 自主 Prompt 优化

参照 [karpathy/autoresearch](#)，本仓库实现：

组件	路径	作用
闭环入口	autoresearch_prompt.py	optimize → evaluate → register → 下一轮
错例分析	src/failure_analysis.py	聚类 empty / too_verbose / wrong_entity 等

组件	路径	作用
版本注册	src/prompts_autoresearch.py	system/user 模板版本化
子集评测	src/infer_autoresearch_task7_eval.py	seed 抽样 N 条，写 autoresearch/task7/results_v*.jsonl

与 L1 关系：Autoresearch 在 **子集** 上快速改稿；全量最高方案仍为 examples_task7 的 stept prompt（37.81%）。最优 autoresearch 版本需迁入 method_hyb_prompts.register_task_prompt(7, ...) 后再跑全量 infer_examples_compare_task7_*.py。

3. 实验结果（以 examples/ 为主）

3.1 Task 3 — Collatz 列表变换

实验	文件	正确/总数	准确率
基线 ICL	examples/openseek-3-examples-compare.jsonl	3954/3997	98.92%
+后处理（理论）	postprocess_task3_outputs.py	—	≈100%

错例分析：43 条错误均为 [input][output] 复述或 <label> 包裹，**无真实算错**。L0 列表抽取即可闭合。

3.2 Task 5 — 推文悲伤二分类

实验依据：examples/openseek-5-*.jsonl 及 examples/summary*.json。

实验配置	结果文件	正确/总数	准确率	备注
基线 compare	openseek-5-examples-compare.jsonl	1407/1899	74.09%	原始 ICL
task5opt	openseek-5-examples-compare-task5opt-emoji-off-striphash-on.jsonl	1426/1899	75.09%	去偏置 + hybrid
emoji-off + striphash	openseek-5-examples-compare-emoji-off-striphash-on.jsonl	1503/1899	79.15%	输入侧预处理
+后处理 eval	openseek-5-examples-compare-emoji-off-striphash-on-pp-eval.jsonl	1540/1899	81.09%	text_calib / emoji 表决
四路投票最优	openseek-5-examples-compare-task5vote-emoji-off-striphash-on.jsonl	1442/1899	75.93%	strip×postemoj 融合
固定 badcase 8-fs	openseek-5-examples-compare-task5opt-fixedbadcase8fs-ret0-emoji-off-striphash-on.jsonl	1397/1899	73.57%	单独 FS 未超融合
中文 emoji 释义	openseek-5-examples-compare-task5opt-zh-translate-emoji-off-striphash-on.jsonl	1435/1899	75.57%	zh_translate
DeepSeek 8-fs+ret4	openseek-5-examples-deepseek-fixedbadcase8fs-ret4-... （500 条）	343/500	68.60%	子集对照

结论：examples 上最高为 **81.09%**（pp-eval 后处理）；纯推理 **79.15%**（emoji-off-striphash-on）。Badcase few-shot 与后处理 **叠加** 优于单一路径；投票在 examples 上未超过单模型最优配置。

3.3 Task 6 — MNLI 同体裁分类

阶段	结果文件	正确/总数	准确率	Δ
v2 句级 AND (base)	openseek-6-examples-compare-task6-v2-sentence-and.jsonl	3418/4954*	68.99%	—
+ postprocess v2	openseek-6-examples-compare-task6-v2-sentence-and-postprocess-v2.jsonl	2235/2673*	83.61%	+14.6ppt
v3 句级 + v2 后处理 (全量)	openseek-6-examples-compare-task6-v3-sentence-and-postprocess.jsonl	4571/5500	83.11%	+14.1pp
summary 记录 base	同上 v3 文件 metadata	3797/5500	69.04%	官方汇总

* 部分 JSONL 为断点续跑子集，全量以 **5500 条 / summary_task6_v3.json** 为准。
† 子集文件准确率偏高，不作为最终结论。

错例驱动设计：

- **v2**：N+N → 同领域判定；Y+N / N+Y → 带上下文重判另一句。
- **v3**：仍为 N 时做语篇连贯复核， flip_gate=not_fiction 抑制 fiction 误翻转。

3.4 Task 7 — Jeopardy 答案生成

实验依据： examples/openseek-7-examples-compare-task7opt*.jsonl 及 summary_task7opt*.json 。

版本	结果文件	正确/总数	准确率
基线 task7opt	openseek-7-examples-compare-task7opt.jsonl	1584/5499	28.81%
v3 (summary 全量)	openseek-7-examples-compare-task7opt-v3.jsonl	1710/5499	31.10%
v5	openseek-7-examples-compare-task7opt-v5.jsonl	1895/5499	34.46%
v6 auto-agent	openseek-7-examples-compare-task7opt-v6.jsonl	1989/5499	36.17%
stept (全量最高)	examples_task7/openseek-7-examples-compare-task7opt-stept-prompt.jsonl	2079/5499	37.81%

examples/ 下 v3 JSONL 仅 8 条（中断跑）；全量指标以 summary_task7opt_v3.json 为准。

Autoresearch (L2)：在子集上循环改 prompts_autoresearch.py ；全量定型仍依赖 stept / v6 手工模板 + 可选外循环审核（infer_examples_compare_task7_v6.py）。

3.5 Task 8 — Triton Kernel 生成

判据	文件	正确/总数	准确率
字符串 is_match	examples/openseek-8-examples-compare-task8opt.jsonl	0/184	0%
exec_dual_pass	examples_thinking/openseek-8-examples-compare-task8opt.jsonl	137/184	74.46%

说明：代码生成任务必须用 **执行器** 评测； examples/ 内字符串匹配文件仅说明「不可按文本判分」。v3 管线（契约 + AST + ReAct + BM25 ICL）见 src/infer_examples_compare_task8_v3.py 。

3.6 Task 1 / 2 / 4（补充数据源）

以下任务 **不在** examples/ 目录，但为八任务完整实验链；一并列入报告。

Task	最佳结果文件	准确率	手段
1	examples_main1_ranktest/.../openseek-1-examples-main1-compare.jsonl	97.93% (5386/5500)	main1 ICL；L0 可达 ≈99.95%

Task	最佳结果文件	准确率	手段
2	examples_main1/openseek-2-examples-main1-compare_spacy_v3_prompt2_zeroshot.jsonl	89.17% (4851/5440)	spaCy 零样本 prompt2
2 基线	examples_main1/openseek-2-examples-main1-compare_v2.jsonl	70.42%	main1 ICL
4	examples_main1_task24/openseek-4-examples-main1-compare-checked.jsonl	100% (2815/2815)	postprocess_task4_outputs

4. 跨任务对比与讨论

4.1 提升来源分解

收益类型	适用任务	典型增益
L0 格式修复	1, 3, 4	+1–3pp (Task 1 近饱和)
L1 领域 prompt / 拆管线	2, 5, 6, 8	+7–19pp
L1 badcase few-shot	5	与预处理叠加达 +7pp
L1 投票融合	5, 6	Task5 examples 未超单模；Task6 test 三路融合
L2 Autoresearch	7	子集迭代，全量需与 stept 合并

4.2 失败模式与对策映射

失败模式	观测任务	对策
<label> 残留 / 空输出	1, 3	postprocess_task1/3_outputs
输出 ≠ ''.join(input)	4	task4 checked 覆盖
emoji / hashtag 偏置	5	strip #、emoji 表决、fp_suppress
句级皆 N 但体裁一致	6	postprocess v2 同领域 / 上下文
答案类型错 / 过长	7	Category+Clue 约束、stept、autoresearch
不可执行 / 无 def	8	v3 契约、AST 门控、ReAct

4.3 局限性

- 1. **examples 与 test 分布差异**：Task 5/7 提交准确率（约 79% / 28%）低于或不同于 examples 最优。
- 2. **部分 JSONL 为断点续跑子集**：解读需优先看 summary*.json 的 total 字段。
- 3. **Autoresearch** 当前仅 Task7 注册表完善；Task 5 FP/FN 模板自动化仍待扩展。
- 4. **Task 8** 在 examples/ 下字符串指标无意义，须单独报告执行器指标。

5. 推荐生产配置（冻结）

Task	examples 最佳	推荐脚本 / 产物
1	97.93% + L0	postprocess_task1_outputs.py
2	89.17%	infer_examples_main1_task2_spacy_v3.py (prompt2 变体)
3	98.92% + L0	postprocess_task3_outputs.py
4	100% checked	postprocess_task4_outputs.py
5	81.09% pp-eval	infer_examples_compare_task5.py + postprocess_task5_outputs.py

Task	examples 最佳	推荐脚本 / 产物
6	83.11%	infer_examples_compare_task6_v3.py + scripts/run_task6_vote_fusion.py
7	37.81% stept	examples_task7 stept 模板 + 可选 v6 审核
8	74.46% exec	infer_examples_compare_task8_v3.py + thinking

6. 复现与文件索引

6.1 examples/ 目录实验清单

```
examples/
├─ openseek-3-examples-compare.jsonl          # Task3  98.92%
├─ openseek-5-examples-compare.jsonl          # Task5  74.09% 基线
├─ openseek-5-examples-compare-emoji-off-striphash-on.jsonl      # 79.15%
├─ openseek-5-examples-compare-emoji-off-striphash-on-pp-eval.jsonl  # 81.09%
├─ openseek-5-examples-compare-task5vote-*.jsonl                # 投票 75.9%
├─ openseek-6-examples-compare-task6-v2-sentence-and.jsonl      # 68.99%
├─ openseek-6-examples-compare-task6-v3-sentence-and-postprocess.jsonl  # 83.11%
├─ openseek-7-examples-compare-task7opt*.jsonl                  # 28.8%-36.2%
├─ openseek-8-examples-compare-task8opt.jsonl                    # 0% 字符串
└─ summary*.json                                                # 各实验汇总
```

6.2 Autoresearch

```
python autoresearch_prompt.py --continuous --max-iterations 10
python autoresearch_prompt.py --results examples/openseek-7-examples-compare-task7opt-v6.jsonl --dry-run
```

6.3 相关文档

- 快速开始与命令摘录: [READMD_cn.md](#)
- 数据集说明: [data/README_zh.md](#)

7. 结论

- 分层策略有效**: L0 解决格式假阴性; L1 带来主要语义增益; L2 适合 Task 7 等开放 prompt 任务。
- Badcase 分析是 Task 5/6 提升关键**: 固定 few-shot、句级拆解与后处理规则均来自 is_match=false 聚类。
- examples 实测最佳**: Task 5 **81.09%**、Task 6 **83.11%**、Task 7 **37.81%** (stept)、Task 8 **74.46%** (执行器); Task 1–4 在饱和区靠 L0 闭合。
- Autoresearch 与手工 stept/v6 互补**: 前者加速子集试错, 后者在全量 examples 上定型。

报告生成依据: 仓库内 examples/、examples/summary*.json 及关联目录 compare 结果; 统计日期与代码版本以 Git 工作区为准。